

UNIVERSIDADE FEDERAL DE PELOTAS
Centro de Desenvolvimento Tecnológico
Programa de Pós-Graduação em Computação



Análise de Ancestralidade Genômica

Isabel Irigon Salaberry

Isabel Irigon Salaberry

Análise de Ancestralidade Genômica

Trabalho Individual apresentado ao Programa de Pós-Graduação em Computação do Centro de Desenvolvimento Tecnológico da Universidade Federal de Pelotas, como requisito parcial à obtenção do título de Mestre em Mestrado em Computação.

Orientador: Prof. Paulo Ferreira Jr.

Pelotas, 2026

RESUMO

Este trabalho apresenta o desenvolvimento de uma análise computacional de afinidade populacional a partir de dados de genotipagem por microarray, utilizando como referência as 26 populações do 1000 Genomes Project. O pipeline incluiu leitura e harmonização dos genótipos, codificação em dosagem do alelo alternativo, controle de qualidade, cálculo de frequências alélicas, seleção de marcadores informativos, *linkage disequilibrium pruning*, análise de componentes principais (PCA), classificação supervisionada por k-vizinhos mais próximos (k-NN), distância a centroides populacionais e um modelo simplificado de mistura por frequências alélicas. O arquivo individual continha 654.027 SNPs, dos quais 572.011 apresentavam correspondência no mapa de harmonização. Após a conversão dos genótipos, 302.919 SNPs permaneceram válidos; o *LD pruning* reteve 208.737 marcadores, e 50.000 SNPs foram utilizados na análise principal. O modelo de mistura apresentou maior contribuição relativa para a superpopulação europeia (85,28%), seguida de americana miscigenada (13,15%) e africana (1,57%). Entre as populações de referência, IBS, TSI e CEU apresentaram os maiores pesos. A PCA posicionou o indivíduo dentro da região europeia, e a população IBS foi a mais próxima do indivíduo no espaço dos dez primeiros componentes principais. O k-NN direto classificou o indivíduo como IBS, enquanto a abordagem hierárquica produziu EUR → IBS. Na validação interna em cinco partições estratificadas, foram obtidas acurácia Top-1 de 80,51%, Top-3 de 98,34% e acurácia de superpopulação de 99,63%. Os resultados indicam boa capacidade de distinção em nível continental e menor resolução entre populações geneticamente próximas. Ressalta-se que os pesos, probabilidades e distâncias obtidos representam afinidade relativa em relação ao painel de referência e não devem ser interpretados como porcentagens literais de nacionalidade ou ancestralidade genealógica.

Palavras-chave: genômica populacional; ancestralidade genética; 1000 Genomes; análise de componentes principais.

ABSTRACT

SALABERRY, Isabel Irigon. **Genomic Ancestry Analysis**. Advisor: Paulo Ferreira Jr.. 2026. 30 f. Trabalho Individual (Mestrado em Mestrado em Computação) – Centro de Desenvolvimento Tecnológico, Federal University of Pelotas, Pelotas, 2026.

This work presents a computational population-affinity analysis based on microarray genotype data using the 26 populations of the 1000 Genomes Project as a reference panel. The pipeline included genotype reading and harmonization, alternative-allele dosage encoding, quality control, allele-frequency estimation, informative-marker selection, linkage disequilibrium pruning, principal component analysis (PCA), supervised k-nearest neighbors (k-NN) classification, population-centroid distances, and a simplified allele-frequency mixture model. The individual genotype file contained 654,027 SNPs, of which 572,011 matched the harmonization map. After genotype conversion, 302,919 SNPs remained valid; LD pruning retained 208,737 markers, and 50,000 SNPs were used in the main analysis. The mixture model yielded the highest relative contribution for the European superpopulation (85.28%), followed by Admixed American (13.15%) and African (1.57%). Among reference populations, IBS, TSI, and CEU received the largest weights. PCA placed the individual within the European region, and IBS was the closest population in the ten-dimensional principal-component space. Direct k-NN classified the individual as IBS, while the hierarchical strategy yielded EUR → IBS. Five-fold stratified internal validation achieved 80.51% Top-1 accuracy, 98.34% Top-3 accuracy, and 99.63% superpopulation accuracy. These results indicate strong discrimination at the continental level and lower resolution among genetically close populations. The reported weights, probabilities, and distances represent relative affinity to the available reference panel and should not be interpreted as literal percentages of nationality or genealogical ancestry.

Keywords: population genomics; genetic ancestry; 1000 Genomes; principal component analysis.

LISTA DE FIGURAS

Figura 1	PCA PC1 × PC2 por superpopulação, com o indivíduo destacado por uma estrela.	16
Figura 2	PCA PC1 × PC2 para as 26 populações do painel de referência. . .	17
Figura 3	PCA PC2 × PC3 por superpopulação.	18
Figura 4	PCA PC3 × PC4 por superpopulação.	18
Figura 5	PCA focal nas cinco populações com menor distância ao indivíduo.	20
Figura 6	Contribuição relativa do modelo de mistura agregada por superpopulação.	21
Figura 7	Contribuição relativa do modelo de mistura para as 26 populações do 1000 Genomes.	22
Figura 8	Matriz de confusão 26 × 26 obtida na validação interna.	23

LISTA DE TABELAS

Tabela 1	Quantidade de SNPs em cada etapa do pipeline.	14
Tabela 2	Cinco populações mais próximas do indivíduo no espaço PCA. . . .	19
Tabela 3	Pesos relativos do modelo de mistura por superpopulação.	20
Tabela 4	Populações com peso não nulo ou relevante no modelo simplificado de mistura.	21
Tabela 5	Desempenho da validação interna do classificador.	22
Tabela 6	Comparação da análise em função do número de SNPs.	24
Tabela 7	Comparação entre os métodos de inferência utilizados.	25

LISTA DE ABREVIATURAS E SIGLAS

AFR	African
AMR	Admixed American
EAS	East Asian
EUR	European
IBS	Iberian Population in Spain
LD	Linkage Disequilibrium
PCA	Principal Component Analysis
SAS	South Asian
SNP	Single Nucleotide Polymorphism
k-NN	k-Nearest Neighbors

SUMÁRIO

1	INTRODUÇÃO	9
1.1	Objetivo geral	9
1.2	Objetivos específicos	10
2	FUNDAMENTAÇÃO	11
2.1	1000 Genomes e referência populacional	11
2.2	Representação dos genótipos	11
2.3	Frequências alélicas e SNPs informativos	11
2.4	Linkage disequilibrium e PCA	12
2.5	Classificação supervisionada	12
3	METODOLOGIA	13
3.1	Dados e ambiente computacional	13
3.2	Harmonização e controle de qualidade	13
3.3	LD pruning e seleção de SNPs	14
3.4	Imputação e PCA	14
3.5	Classificação k-NN	15
3.6	Modelo simplificado de mistura	15
3.7	Validação interna	15
4	RESULTADOS E DISCUSSÃO	16
4.1	Estrutura populacional observada pela PCA	16
4.2	Distância aos centroides	19
4.3	Modelo de mistura por frequências	20
4.4	Classificação supervisionada	22
4.5	Efeito do número de SNPs	24
4.6	Comparação entre métodos	24
4.7	Limitações	25
5	CONCLUSÃO	27
	REFERÊNCIAS	28
	APÊNDICE A RESUMO DO PIPELINE COMPUTACIONAL	30

1 INTRODUÇÃO

A genotipagem por microarray permite observar centenas de milhares de variantes genéticas distribuídas pelo genoma. Quando esses dados são comparados a painéis populacionais de referência, torna-se possível estudar padrões de proximidade genética e estrutura populacional. Entretanto, essa inferência depende de várias etapas computacionais: compatibilização das variantes, tratamento de genótipos ausentes, redução de correlações entre marcadores, construção de representações de menor dimensionalidade e escolha de métodos adequados de classificação e comparação.

Neste trabalho foi desenvolvido um pipeline de análise de ancestralidade e afinidade populacional para um indivíduo genotipado em microarray Illumina, utilizando como painel de referência dados preparados a partir do 1000 Genomes Project. O conjunto de referência contempla 26 populações agrupadas em cinco superpopulações: AFR, AMR, EAS, EUR e SAS. O projeto foi desenvolvido no contexto da disciplina de Aprendizado em Genômica do Programa de Pós-Graduação em Computação da Universidade Federal de Pelotas, seguindo o fluxo metodológico proposto no material da disciplina (Ferreira jr., 2026).

A interpretação dos resultados requer cautela. As populações presentes no 1000 Genomes são populações contemporâneas e não correspondem a “ancestrais puros”. Além disso, grupos como PUR, CLM, MXL e PEL possuem histórias demográficas marcadas por miscigenação. Assim, uma proximidade com determinada população de referência não deve ser traduzida diretamente em porcentagem de nacionalidade ou origem genealógica. O resultado expressa semelhança genética relativa dentro do conjunto de referências disponível.

1.1 Objetivo geral

O objetivo geral foi implementar e avaliar uma calculadora computacional de afinidade populacional capaz de posicionar o genoma de um indivíduo em relação às 26 populações do 1000 Genomes, combinando métodos exploratórios, supervisionados e de mistura por frequências alélicas.

1.2 Objetivos específicos

Os objetivos específicos foram:

- converter os genótipos do microarray para a mesma codificação da referência;
- calcular frequências do alelo ALT globalmente e por população;
- selecionar SNPs informativos e reduzir a dependência entre variantes por *LD pruning*;
- realizar PCA e projetar o indivíduo sem utilizá-lo no ajuste dos componentes;
- calcular distâncias entre o indivíduo e centroides das 26 populações;
- implementar classificação por k-NN direta e hierárquica;
- ajustar um modelo simplificado de mistura populacional baseado em frequências alélicas;
- validar internamente a classificação por Top-1, Top-3, acurácia de superpopulação e matriz de confusão;
- avaliar o efeito do número de SNPs na estabilidade e no desempenho da análise.

2 FUNDAMENTAÇÃO

2.1 1000 Genomes e referência populacional

O 1000 Genomes Project consolidou um painel de variação genética humana amplamente utilizado para estudos de genética de populações e comparação de frequências alélicas (The 1000 Genomes Project Consortium, 2015). Neste trabalho, foram consideradas 26 populações distribuídas em cinco grandes grupos populacionais: AFR, AMR, EAS, EUR e SAS. A referência utilizada já havia sido previamente reduzida e harmonizada para os marcadores compatíveis com o microarray da atividade, evitando a necessidade de repetir o processamento integral do conjunto original.

2.2 Representação dos genótipos

Cada SNP bialélico foi representado pela dosagem do alelo ALT. Para uma variante com alelos REF e ALT, utilizaram-se os códigos

$$g_i = \begin{cases} 0, & \text{REF/REF,} \\ 1, & \text{REF/ALT,} \\ 2, & \text{ALT/ALT,} \\ -9, & \text{ausente ou incompatível.} \end{cases} \quad (1)$$

A mesma orientação de alelos deve ser empregada no indivíduo e na referência. Por isso, a harmonização é uma etapa essencial: uma correspondência incorreta entre REF e ALT pode inverter a interpretação das dosagens e introduzir artefatos nas análises posteriores.

2.3 Frequências alélicas e SNPs informativos

Para cada SNP, a frequência do alelo ALT foi estimada por

$$p_i = \frac{\sum_j g_{ji}}{2N_i}, \quad (2)$$

em que N_i representa o número de indivíduos com genótipo válido na variante i . O mesmo cálculo foi realizado separadamente para cada uma das 26 populações de referência.

Como medida simples de diferenciação entre populações, foi utilizado

$$\Delta p_i = \max_k(p_{ik}) - \min_k(p_{ik}), \quad (3)$$

onde p_{ik} é a frequência ALT do SNP i na população k . SNPs com maior Δp_i apresentam maior variação de frequência entre os grupos de referência e, portanto, tendem a ser mais informativos para discriminação populacional no contexto deste método didático.

2.4 Linkage disequilibrium e PCA

Variantes próximas podem apresentar correlação devido ao desequilíbrio de ligação (LD). A manutenção de grande número de SNPs altamente correlacionados pode fazer regiões específicas do genoma receberem peso excessivo. Para reduzir esse efeito foi utilizado o procedimento `-indep-pairwise 50 5 0.2` do PLINK 2, ferramenta amplamente empregada no processamento de dados genômicos (Chang; Chow; Teller; Vattikuti; Purcell; Lee, 2015).

A PCA transforma a matriz genotípica em eixos ortogonais de variação. Em genética de populações, os primeiros componentes frequentemente capturam gradientes de estrutura genética e permitem visualizar diferenças entre grupos (Price; Patterson; Plenge; Weinblatt; Shadick; Reich, 2006). Neste trabalho, a PCA foi ajustada exclusivamente com os indivíduos da referência, e o indivíduo analisado foi projetado posteriormente no espaço aprendido, evitando que sua própria informação alterasse os componentes.

2.5 Classificação supervisionada

O k-NN atribui uma observação à classe predominante entre seus vizinhos mais próximos. Foi utilizado $k = 15$ com pesos inversamente relacionados à distância. A classificação foi executada em duas estratégias: uma classificação direta entre as 26 populações e uma classificação hierárquica, na qual primeiro foi estimada a superpopulação e, em seguida, a população específica dentro do grupo selecionado. A implementação foi realizada com ferramentas da biblioteca scikit-learn (Pedregosa; Varoquaux; Gramfort; Michel; Thirion; Grisel; Blondel; Prettenhofer; Weiss; Dubourg; Vanderplas; Passos; Cournapeau; Brucher; Perrot; Duchesnay, 2011).

3 METODOLOGIA

3.1 Dados e ambiente computacional

A análise foi realizada em Python no Google Colab, com os dados armazenados no Google Drive. A referência foi fornecida no formato PLINK 2, composta pelos arquivos `1000G_GSA_SNP.pgen`, `1000G_GSA_SNP.pvar.zst` e `1000G_GSA_SNP.psam`. O indivíduo foi fornecido no arquivo `genotipo_microarray.csv`. A conversão entre os marcadores do microarray e as variantes da referência utilizou exclusivamente o arquivo `harmonization_map.csv`.

O campo `Name` do microarray foi tratado como identificador do marcador Illumina, e não como `rsID`. O mapa de harmonização forneceu o índice da variante na referência, os alelos `REF` e `ALT` e a indicação `NEEDS_COMPLEMENT`, utilizada para corrigir diferenças de orientação de fita quando necessário.

3.2 Harmonização e controle de qualidade

O arquivo do indivíduo continha 654.027 SNPs. O mapa de harmonização possuía 572.011 marcadores. Após a aplicação da orientação de alelos e a conversão para dosagens 0, 1 e 2, 302.919 SNPs apresentaram genótipos válidos e compatíveis.

Nesta execução, o controle de qualidade operacional reteve os SNPs harmonizados com genótipo válido e frequência de referência calculável. Como não foram aplicados limiares adicionais de *call rate* ou MAF, o número de marcadores após QC permaneceu igual a 302.919. Essa decisão é relevante para a reprodutibilidade e deve ser considerada na interpretação dos resultados.

A Tabela 1 resume a redução do conjunto de marcadores.

Tabela 1 – Quantidade de SNPs em cada etapa do pipeline.

Etapa	Número de SNPs
Arquivo de microarray	654.027
Encontrados no mapa de harmonização	572.011
Após harmonização	302.919
Após QC	302.919
Após LD pruning	208.737
Utilizados na análise principal	50.000

Fonte: Elaborada pela autora.

3.3 LD pruning e seleção de SNPs

O *LD pruning* foi realizado com janela de 50 variantes, deslocamento de 5 variantes e limiar de $r^2 = 0,2$. Esse procedimento reduziu o conjunto de 302.919 para 208.737 SNPs. Em seguida, os SNPs remanescentes foram ordenados de acordo com Δp , e os 50.000 marcadores mais informativos foram usados na análise principal.

Para investigar a sensibilidade ao número de variantes, o pipeline foi repetido com 1.000, 5.000, 10.000, 20.000 e 50.000 SNPs.

3.4 Imputação e PCA

Os genótipos ausentes foram imputados pela dosagem média esperada do alelo ALT, dada por $2p_i$, onde p_i é a frequência ALT estimada na referência. Foram calculados dez componentes principais utilizando o algoritmo randomizado de PCA. O modelo foi ajustado somente na matriz de referência, e o indivíduo foi posteriormente transformado pela mesma projeção.

A proximidade com cada população foi calculada no espaço formado pelos dez componentes. Para cada população k , foi calculado o centroide c_k como a média das coordenadas dos indivíduos do grupo. A distância foi definida por

$$d_k = \|\mathbf{x}_{\text{ind}} - \mathbf{c}_k\|_2. \quad (4)$$

Quanto menor d_k , maior a proximidade do indivíduo ao centro da população no espaço PCA. Essa distância não corresponde a porcentagem de ancestralidade.

3.5 Classificação k-NN

Para a classificação direta foram utilizados os dez componentes principais como variáveis de entrada e as 26 populações como classes. O k-NN foi configurado com 15 vizinhos e ponderação por distância. A estratégia hierárquica utilizou o mesmo princípio, classificando primeiro entre AFR, AMR, EAS, EUR e SAS e, depois, entre as populações pertencentes à superpopulação selecionada.

3.6 Modelo simplificado de mistura

Para cada SNP i e população k , seja p_{ik} a frequência do alelo ALT. Foram estimados pesos w_k sujeitos às restrições

$$w_k \geq 0, \quad \sum_k w_k = 1. \quad (5)$$

O genótipo esperado no SNP i foi modelado como

$$\hat{g}_i = 2 \sum_k w_k p_{ik}, \quad (6)$$

minimizando-se o erro quadrático médio

$$\min_w \frac{1}{M} \sum_i (g_i - \hat{g}_i)^2. \quad (7)$$

A otimização foi executada pelo método SLSQP. Os pesos foram estimados para as 26 populações e posteriormente agregados segundo as cinco superpopulações. Esse modelo é uma aproximação didática e não substitui métodos especializados de inferência de *admixture*.

3.7 Validação interna


A classificação foi avaliada por validação estratificada em cinco partições. Em cada *fold*, a PCA e o k-NN foram ajustados utilizando apenas os indivíduos de treinamento, e os indivíduos de teste foram tratados como desconhecidos. Foram calculadas as métricas Top-1, Top-3 e acurácia de superpopulação. Também foi construída uma matriz de confusão entre as 26 populações.

4 RESULTADOS E DISCUSSÃO

4.1 Estrutura populacional observada pela PCA

A Figura 1 apresenta PC1 versus PC2 para as cinco superpopulações. Os grandes grupos populacionais ocupam regiões distintas do espaço, embora a superpopulação AMR apresente distribuição mais extensa, compatível com sua história de miscigenação. O indivíduo analisado aparece inserido na região ocupada pelos indivíduos EUR.

Figura 1 – PCA PC1 $\times$ PC2 por superpopulação, com o indivíduo destacado por uma estrela.




Fonte: Elaborada pela autora.

A representação por 26 populações, mostrada na Figura 2, evidencia que a separação dentro de uma mesma superpopulação é mais sutil que a separação continen-

tal. O indivíduo permanece próximo ao conjunto de populações europeias, particularmente à região ocupada por IBS, TSI, CEU e GBR.


Figura 2 – PCA PC1 × PC2 para as 26 populações do painel de referência.



Fonte: Elaborada pela autora.


A inspeção de outros planos confirma a interpretação baseada em PC1 e PC2. Na Figura 3, o indivíduo permanece no agrupamento EUR quando são considerados PC2 e PC3. Em PC3 e PC4 (Figura 4), o indivíduo também acompanha a região ocupada por EUR, indicando que a conclusão não depende exclusivamente do primeiro plano bidimensional.

Figura 3 – PCA PC2 × PC3 por superpopulação.



Fonte: Elaborada pela autora.

Figura 4 – PCA PC3 × PC4 por superpopulação.



Fonte: Elaborada pela autora.

4.2 Distância aos centroides

As cinco populações com menor distância ao indivíduo no espaço dos dez componentes principais são apresentadas na Tabela 2. A população IBS apresentou a menor distância ($d = 5,9592$), seguida de TSI, GBR e CEU. PUR aparece em quinto lugar, porém com distância consideravelmente maior que as quatro primeiras.


Tabela 2 – Cinco populações mais próximas do indivíduo no espaço PCA.

Posição	População	Distância
1	IBS	5,9592
2	TSI	6,6311
3	GBR	9,8523
4	CEU	11,0381
5	PUR	21,6644

Fonte: Elaborada pela autora.

A PCA focal das cinco populações mais próximas (Figura 5) reforça esse resultado. O indivíduo encontra-se junto ao agrupamento europeu formado por IBS, TSI, GBR e CEU, enquanto PUR ocupa uma trajetória mais dispersa no plano $PC1 \times PC2$. Essa dispersão é coerente com o caráter miscigenado da população de Porto Rico no painel de referência.

Figura 5 – PCA focal nas cinco populações com menor distância ao indivíduo.



Fonte: Elaborada pela autora.

4.3 Modelo de mistura por frequências


O modelo simplificado de mistura produziu os pesos agregados mostrados na Tabela 3. O maior valor foi atribuído a EUR (85,28%), seguido de AMR (13,15%) e AFR (1,57%). EAS e SAS receberam pesos numericamente nulos nesta solução.

Tabela 3 – Pesos relativos do modelo de mistura por superpopulação.

Superpopulação	Peso relativo (%)
EUR	85,28
AMR	13,15
AFR	1,57
EAS	0,00
SAS	0,00

Fonte: Elaborada pela autora.

Figura 6 – Contribuição relativa do modelo de mistura agregada por superpopulação.



Fonte: Elaborada pela autora.


No nível das 26 populações, os maiores pesos foram IBS (30,23%), TSI (27,38%) e CEU (16,97%), seguidos por CLM (7,91%), GBR (7,71%), PUR (5,24%), FIN (3,00%) e ASW (1,57%). A Figura 7 apresenta os pesos completos.

Tabela 4 – Populações com peso não nulo ou relevante no modelo simplificado de mistura.

População	Peso relativo (%)
IBS	30,23
TSI	27,38
CEU	16,97
CLM	7,91
GBR	7,71
PUR	5,24
FIN	3,00
ASW	1,57

Fonte: Elaborada pela autora.

Figura 7 – Contribuição relativa do modelo de mistura para as 26 populações do 1000 Genomes.



Fonte: Elaborada pela autora.

Existe concordância qualitativa entre o modelo de mistura e a PCA: ambos apontam para maior afinidade com populações europeias, especialmente IBS e TSI. Ao mesmo tempo, a presença de pesos em CLM, PUR e ASW mostra por que os valores do modelo não devem ser tratados como frações genealógicas exatas. O modelo tenta aproximar os genótipos observados por combinações das frequências disponíveis e pode distribuir peso entre populações correlacionadas para minimizar o erro global. Soluções semelhantes podem ser obtidas por diferentes combinações quando as populações de referência possuem frequências próximas.

4.4 Classificação supervisionada

O k-NN direto atribuiu o indivíduo à população IBS. Na classificação hierárquica, a primeira etapa selecionou EUR, e a segunda etapa novamente classificou o indivíduo como IBS. Esse resultado concorda com a menor distância de centroide observada para IBS e com a posição do indivíduo nos gráficos de PCA.

Na validação interna em cinco partições foram obtidos os resultados da Tabela 5.

Tabela 5 – Desempenho da validação interna do classificador.

Métrica	Resultado (%)
Top-1 accuracy	80,51
Top-3 accuracy	98,34
Accuracy de superpopulação	99,63


Fonte: Elaborada pela autora.

A diferença entre Top-1 e Top-3 é informativa. Embora a população correta seja a primeira opção em aproximadamente 80,5% dos casos, em 98,3% dos indivíduos ela

aparece entre as três classes mais prováveis. Isso sugere que grande parte dos erros ocorre entre populações próximas, e não entre grupos continentais muito distintos. Essa interpretação também é apoiada pela acurácia de superpopulação de 99,63%.

A matriz de confusão da Figura 8 mostra exemplos claros desse comportamento. Observam-se confusões relevantes entre populações pertencentes à mesma superpopulação, como CEU e GBR, ACB e ASW, CDX e KHV, ESN e YRI e diferentes grupos do sul da Ásia. Em contraste, erros entre superpopulações são muito menos frequentes. O resultado indica que a estrutura continental é mais facilmente separável que diferenças finas entre populações geneticamente próximas.

Figura 8 – Matriz de confusão 26×26 obtida na validação interna.



Fonte: Elaborada pela autora.

4.5 Efeito do número de SNPs

A Tabela 6 apresenta o resultado da comparação entre diferentes tamanhos de subconjunto. Em todas as configurações, IBS foi a população mais próxima na análise por centroides, demonstrando estabilidade da conclusão principal. Ao mesmo tempo, a acurácia do k-NN aumentou conforme mais marcadores foram incluídos, passando de 58,03% com 1.000 SNPs para 81,12% com 50.000 SNPs.

Tabela 6 – Comparação da análise em função do número de SNPs.

SNPs	Variância 10 PCs (%)	Distância	Acc. k-NN (%)	Pop. mais próxima
1.000	48,31	1,6995	58,03	IBS
5.000	37,20	2,4178	73,63	IBS
10.000	31,75	3,8775	76,76	IBS
20.000	26,03	4,2881	80,34	IBS
50.000	18,79	5,9592	81,12	IBS

Fonte: Elaborada pela autora.

O percentual de variância explicado pelos dez primeiros componentes diminuiu com o aumento do número de SNPs. Esse comportamento não representa piora da PCA: ao adicionar milhares de novas variáveis, a variância total do conjunto aumenta e passa a ser distribuída por um número maior de dimensões. Mesmo com menor fração da variância total concentrada nos dez primeiros componentes, o desempenho classificatório melhorou, indicando que os conjuntos maiores continham informação adicional útil para a discriminação populacional.

O aumento entre 20.000 e 50.000 SNPs foi menor do que o observado nas etapas iniciais, sugerindo retornos decrescentes. A estabilidade de IBS como população de centroide mais próximo em todos os tamanhos testados é particularmente importante, pois mostra que a conclusão principal não depende de um único número arbitrário de marcadores.

4.6 Comparação entre métodos

A Tabela 7 resume as três abordagens principais. Os métodos não produzem exatamente o mesmo tipo de resultado e, portanto, devem ser interpretados de forma complementar.

Tabela 7 – Comparação entre os métodos de inferência utilizados.

Método	Resultado principal	Vantagens	Limitações
PCA + centroides	Ranking de proximidade no espaço dos componentes	Visualização da estrutura; interpretação geométrica; resultado estável para IBS	Distância depende dos PCs e dos SNPs; não produz proporção biológica
k-NN	Classe populacional prevista	Avaliação objetiva por validação; alta Top-3 e alta acurácia de superpopulação	Força escolha entre classes existentes; confusão entre populações próximas
Mistura por frequências	Pesos não negativos que somam 1	Permite resumir afinidades relativas e agregá-las por superpopulação	Sensível a LD, seleção de SNPs e correlação entre referências; pesos não são porcentagens genealógicas

Fonte: Elaborada pela autora.

Apesar das diferenças, houve convergência entre os métodos. A PCA posicionou o indivíduo na região europeia; IBS apresentou a menor distância ao centroide; o k-NN direto classificou o indivíduo como IBS; a estratégia hierárquica retornou EUR → IBS; e o modelo de mistura atribuiu 85,28% do peso relativo à superpopulação EUR, com IBS apresentando o maior peso individual. A convergência aumenta a confiança de que a principal afinidade capturada pela referência é europeia e, dentro das 26 classes disponíveis, mais próxima de IBS.

4.7 Limitações

Os resultados devem ser interpretados dentro das limitações do desenho experimental. Primeiramente, as 26 populações do 1000 Genomes não constituem uma representação completa de toda a diversidade genética humana. Uma população real ausente do painel pode ser aproximada por uma ou mais referências disponíveis, produzindo pesos ou classificações que refletem a limitação do painel e não uma origem literal.

Em segundo lugar, populações modernas possuem histórias demográficas complexas. As categorias do 1000 Genomes representam amostras contemporâneas, algumas delas miscigenadas. Consequentemente, o peso de uma população no mo-

delo simplificado de mistura não deve ser interpretado como uma fração exata de antepassados pertencentes àquela nacionalidade ou região.

Outras limitações incluem correlação residual entre SNPs, sensibilidade ao conjunto de marcadores selecionado, frequências estimadas em amostras finitas, deriva genética, diferenças no tamanho das amostras populacionais e a possibilidade de soluções não únicas no modelo de mistura. Além disso, a etapa de QC utilizada nesta execução não aplicou filtros adicionais de MAF ou *call rate*; futuros experimentos podem testar o efeito desses critérios.

Finalmente, a alta acurácia de superpopulação não implica resolução equivalente entre as 26 populações. A matriz de confusão mostra que grupos próximos frequentemente compartilham sinal genético suficiente para dificultar a classificação fina. Por isso, a inferência é mais robusta para estrutura populacional ampla do que para atribuições muito específicas.

5 CONCLUSÃO

O trabalho demonstrou que dados de microarray podem ser integrados a um painel do 1000 Genomes para produzir uma análise reprodutível de afinidade populacional. O pipeline reduziu 654.027 SNPs do arquivo original para 302.919 genótipos harmonizados e válidos, 208.737 marcadores após *LD pruning* e 50.000 SNPs informativos na análise principal.

Os métodos utilizados apresentaram resultados consistentes. A PCA posicionou o indivíduo no agrupamento europeu em diferentes combinações de componentes principais. No espaço dos dez PCs, IBS foi a população de referência mais próxima, seguida por TSI, GBR e CEU. O classificador k-NN retornou IBS tanto na classificação direta quanto na etapa populacional do modelo hierárquico EUR → IBS. O modelo de mistura apresentou 85,28% de peso relativo para EUR, com maiores componentes em IBS, TSI e CEU.

A validação mostrou que a classificação possui boa capacidade de discriminação: 80,51% de acurácia Top-1, 98,34% de Top-3 e 99,63% em nível de superpopulação. A diferença entre essas métricas e os padrões observados na matriz de confusão evidenciam que a maior dificuldade se encontra na distinção entre populações geneticamente próximas. A comparação entre subconjuntos também mostrou aumento da acurácia com mais SNPs, ao mesmo tempo em que IBS permaneceu como população mais próxima em todas as configurações de 1.000 a 50.000 marcadores.

Dessa forma, é possível inferir de maneira útil a afinidade genética de um indivíduo a partir de um microarray comercial e das 26 populações do 1000 Genomes, principalmente em escalas populacionais amplas. Entretanto, a resolução da inferência é limitada pela composição da referência, seleção de SNPs, LD, semelhança entre populações, miscigenação e incerteza estatística. Os resultados devem ser apresentados como medidas relativas de proximidade ao painel analisado, e não como porcentagens literais de ancestralidade biológica ou nacionalidade.

REFERÊNCIAS

CHANG, C. C.; CHOW, C. C.; TELLIER, L. C. A. M.; VATTIKUTI, S.; PURCELL, S. M.; LEE, J. J. Second-generation PLINK: rising to the challenge of larger and richer datasets. **GigaScience**, [S.l.], v.4, n.1, p.7, 2015.

FERREIRA JR., P. **Projeto Prático**: Calculadora de Ancestralidade Genômica com o 1000 Genomes. Material da disciplina Aprendizado em Genômica, Programa de Pós-Graduação em Computação, Universidade Federal de Pelotas.

PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISSEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COURNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY, E. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, [S.l.], v.12, p.2825–2830, 2011.

PRICE, A. L.; PATTERSON, N. J.; PLENGE, R. M.; WEINBLATT, M. E.; SHADICK, N. A.; REICH, D. Principal components analysis corrects for stratification in genome-wide association studies. **Nature Genetics**, [S.l.], v.38, n.8, p.904–909, 2006.

The 1000 Genomes Project Consortium. A global reference for human genetic variation. **Nature**, [S.l.], v.526, p.68–74, 2015.

Apêndices

APÊNDICE A – Resumo do pipeline computacional

O fluxo executado no Google Colab pode ser resumido nas seguintes etapas:

1. montagem do Google Drive e definição dos caminhos dos arquivos;
2. leitura do PSAM, PVAR e PGEN da referência;
3. leitura do `harmonization_map.csv`;
4. conversão do microarray individual para dosagens REF/ALT;
5. cálculo das frequências ALT globais e por população;
6. seleção dos SNPs com genótipo válido e execução do QC;
7. cálculo de Δp ;
8. *LD pruning* com `-indep-pairwise 50 5 0.2`;
9. seleção dos 50.000 SNPs mais informativos para a análise principal;
10. imputação por $2p_i$;
11. PCA da referência e projeção do indivíduo;
12. cálculo de centroides e distâncias;
13. k-NN direto e hierárquico;
14. modelo de mistura por frequências;
15. validação estratificada em cinco partições;
16. comparação entre 1.000, 5.000, 10.000, 20.000 e 50.000 SNPs.

O notebook utilizado na execução deve ser preservado juntamente com as saídas e as versões dos arquivos de referência para garantir a reprodutibilidade da análise.